

# RAPPORT TECHNIQUE

Système de Stratification Probabiliste des Réponses  
Ovariennes en Fécondation In Vitro

Code source GitHub : [https://github.com/YesmineZhioua/Tanit\\_ML - Data.git](https://github.com/YesmineZhioua/Tanit_ML - Data.git)

7 décembre 2025

## Table des matières

---

<b>1 INTRODUCTION ET CONTEXTE</b>	<b>4</b>
1.1 Contexte du Projet . . . . .	4
1.2 Objectifs du Projet . . . . .	4
1.3 Enjeux Cliniques . . . . .	4
<b>2 DESCRIPTION DU DATASET ET DES VARIABLES</b>	<b>5</b>
2.1 Sources de Données . . . . .	5
2.2 Variables du Dataset . . . . .	5
<b>3 Architecture Global</b>	<b>5</b>
3.1 Technologie utilisées . . . . .	6
3.2 Architecture du Projet . . . . .	6
<b>4 Phase1 : EXTRACTION DES DONNÉES PDF</b>	<b>6</b>
4.1 Les etapes de l'extraction . . . . .	6
4.2 Structuration et Intégration . . . . .	8
4.3 Visualisation des résultats . . . . .	8
4.4 Défis de cette phase : . . . . .	9
<b>5 Phase 2 : Analyse Exploratoire des Données (EDA)</b>	<b>10</b>
5.1 Objectifs . . . . .	10
5.2 Statistiques Descriptives . . . . .	10
5.3 Analyse des Corrélations . . . . .	11
5.4 Insights Cliniques et Patterns . . . . .	12
5.4.1 Visualisation des Distributions . . . . .	13
<b>6 Phase3 : Prétraitement et Nettoyage</b>	<b>15</b>
6.0.1 Détection et Gestion des Valeurs Manquantes . . . . .	15
6.0.2 Détection des Valeurs Aberrantes . . . . .	17
6.0.3 Détection des Doubloons . . . . .	17
6.0.4 Normalisation des Variables Numériques . . . . .	18
6.0.5 Encodage des Variables Catégorielles . . . . .	18
<b>7 Phase 4 : Entraînement des ML</b>	<b>19</b>
7.1 Objectif . . . . .	19
7.2 Algorithmes Utilisés . . . . .	19
7.3 Étapes Principales de l'Entraînement . . . . .	20
7.4 Résultat Attendu . . . . .	21
<b>8 Phase 5 : Évaluation et Choix du Modèle</b>	<b>22</b>
8.1 Stratégie d'Évaluation . . . . .	22
8.2 Modèles Évalués . . . . .	22
8.3 Métriques d'Évaluation . . . . .	22
8.4 Analyse et Visualisations . . . . .	24
8.5 Sélection du Meilleur Modèle . . . . .	25

<b>9 Phase 6 : Prédiction</b>	<b>26</b>
9.1 Objectif . . . . .	26
9.2 Chargement du Modèle . . . . .	26
9.3 Prétraitement des Données . . . . .	26
9.4 Prédiction . . . . .	26
9.5 Interprétation Clinique et Recommandations . . . . .	27
9.6 Exemple de Prédiction . . . . .	27
9.7 Résumé . . . . .	27
<b>10 Phase 7 : Interface Utilisateur et Intégration du Modèle</b>	<b>29</b>
10.1 Description . . . . .	29
<b>11 Perspectives Importantes</b>	<b>33</b>
11.1 Recommandation avec LLM . . . . .	33
11.2 Visualisation du pipeline . . . . .	33
11.3 Documentation et mots-clés . . . . .	33
11.4 Version et contraintes . . . . .	33

## 1 INTRODUCTION ET CONTEXTE

---

### 1.1 Contexte du Projet

La fécondation in vitro (FIV) représente une technologie médicale complexe où la prédiction de la réponse ovarienne aux stimulations hormonales constitue un défi clinique majeur. Ce projet vise à développer un système de classification probabiliste permettant de stratifier les patientes selon leur réponse attendue : faible (low), optimale (optimal) ou élevée (high).

### 1.2 Objectifs du Projet

#### Objectif Principal

Développer un modèle de classification interprétable capable de prédire avec précision la réponse ovarienne des patientes, en fournissant des probabilités associées à chaque classe (ex : «68% de chance que cette patiente soit high responsive»).

#### Objectifs Secondaires

- Extraire et structurer les données médicales non structurées (PDF)
- Anonymiser les données patients selon les normes RGPD
- Identifier les biomarqueurs prédictifs significatifs
- Développer une interface d'inférence utilisable cliniquement
- Assurer l'interprétabilité des prédictions via SHAP/LIME

### 1.3 Enjeux Cliniques

La stratification précoce et précise des patientes permet :

**Optimisation thérapeutique** : Adaptation des protocoles de stimulation selon le profil

**Réduction des risques** : Prévention du syndrome d'hyperstimulation ovarienne (SHSO)

**Amélioration des résultats** : Augmentation des taux de réussite par cycle

**Personnalisation des soins** : Traitement individualisé basé sur les biomarqueurs

**Optimisation économique** : Réduction des coûts et du temps de traitement

## 2 DESCRIPTION DU DATASET ET DES VARIABLES

### 2.1 Sources de Données

**Données Structurées** : Fichier CSV contenant les dossiers des patients.

**Données Non Structurées** : Document PDF représente les données médical d'un patient.

### 2.2 Variables du Dataset

Variable	Type	Description Clinique
Patient_id	Catégoriel	Identifiant anonymisé unique
Cycle_number	Numérique entier	Numéro de tentative de FIV (historique)
Age	Numérique	Âge de la patiente au moment du cycle
Protocol	Catégoriel	Type de protocole de stimulation ovarienne : fixed antagonist / flexible antagonist / agonist
AMH	Numérique continu	Hormone Anti-Müllerienne (ng/mL)
N_Follicles	Numérique entier	Nombre de follicules au dernier jour monitoré
E2_day5	Numérique continu	Niveau d'estradiol au jour 5 de stimulation
AFC	Numérique entier	Compte de follicules antraux à l'échographie
Patient_Response	Catégoriel (CIBLE)	Stratification de la réponse ovarienne :low / optimal / high

TABLE 1 – Variables du dataset

## 3 Architecture Global

PDF → Extraction → EDA → Nettoyage → Entraînement → Évaluation → Déploiement .

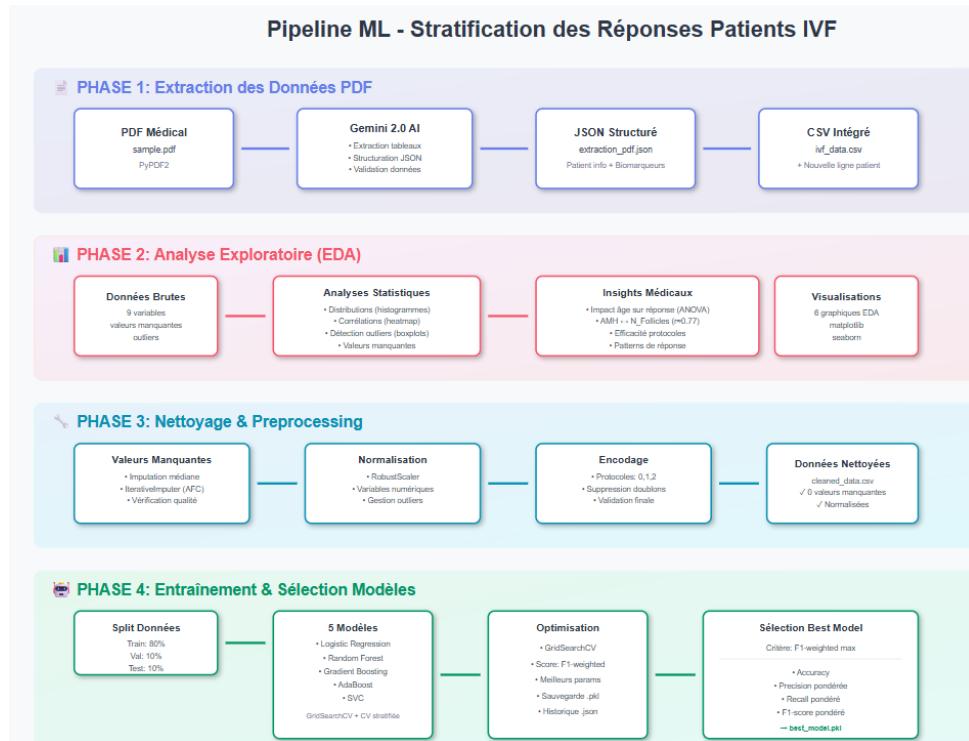


FIGURE 1 – Pipeline

### 3.1 Technologie utilisées

**Extraction :** PyPDF2 , Google Gemini 2.0 AI  
**Traitement :** Pandas , Numpy , Scikit-learn  
**visualisation :** Matplotlib , Seaborn  
**Modélisation :** Scikit-learn (Logistic Regression, Random Forest, Gradient Boosting, AdaBoost, SVC)  
**Back :** Python , Flask  
**Front :** Streamlit

### 3.2 Architecture du Projet

## 4 Phase1 : EXTRACTION DES DONNÉES PDF

### 4.1 Les etapes de l'extraction

L'extraction des données du document PDF médical nécessite une approche hybride combinant :

- **Etape 1 : Extraction du texte brut avec PyPDF2**
- **Etape 2 : Structuration intelligente avec Gemini 2.0 :**  
Nous avons utilisé Google Gemini 2.0 avec un prompt engineering précis pour identifier

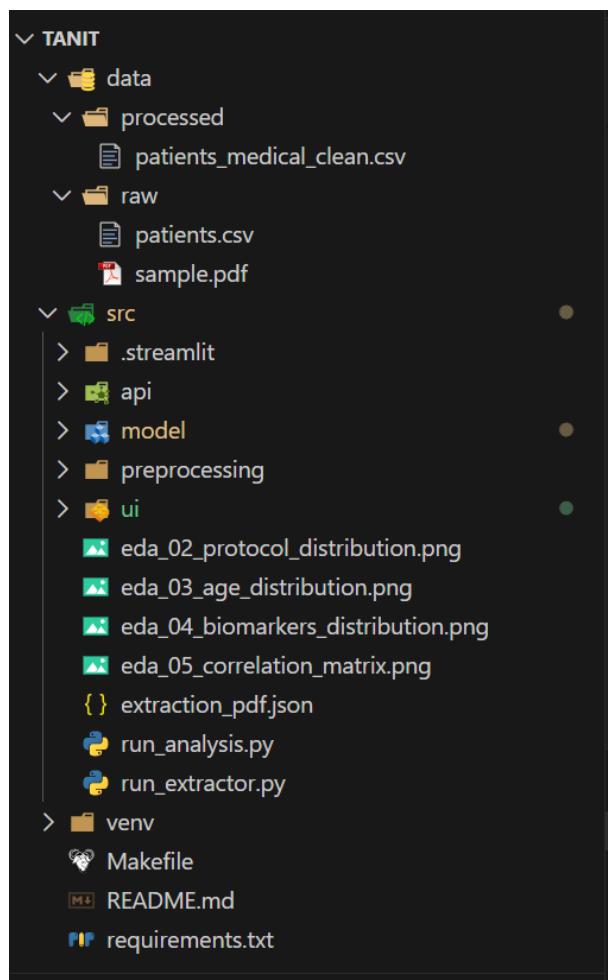


FIGURE 2 – Architecture du code source

les en-têtes de tableaux, Extraire les valeurs exactes(préservation des formats "10/8", "225UI") et générer un JSON structuré validé

#### — Étape 3 : Validation et nettoyage du JSON

#### — Étape 4 : Intégration dans le CSV :

Mapping intelligent des données extraites vers les colonnes du dataset :

- Génération automatique du format patientID en (format 25XXX)
- Extraction depuis "2nd " -> 2

-Calcul age depuis date de naissance

-Standariser le Protocol

## 4.2 Structuration et Intégration

Une fois les données extraites du PDF :

1. Conversion en format structuré (CSV/JSON)
2. Validation du schéma de données (types, plages)
3. Ajout d'une nouvelle ligne au CSV existant avec tous les champs requis
4. Vérification de la cohérence avec les données existantes

## 4.3 Visualisation des résultats

```
yesmine@Yassou MINGW64 ~/Desktop/Tanit/src (yasmine)
$ python run_extractor.py
=====
👉 Lecture du JSON : extraction_pdf.json
✓ Données extraites pour le patient : 25502
✓ CSV existant trouvé : C:\Users\yesmine\Desktop\tanit\data\raw\patients.csv

👉 Ajout de la ligne au CSV...
✓ Patient ajouté : 25502

✅ DONNÉES AJOUTÉES AVEC SUCCÈS !
👉 Fichier CSV mis à jour : C:\Users\yesmine\Desktop\tanit\data\raw\patients.csv

👉 DONNÉES EXTRAITES ET AJOUTÉES :
-----
• Patient_id          : 25502
• Cycle_number        : 1
• Age                 : 30
• Protocol            : flexible antagonist
• AMH                 : 3.64 ng/mL
• N_Follicles         : 9
• E2_day5             : 350 pg/mL
• AFC                 : ✗ Non trouvé
• Patient_Response    : optimal
-----
```

FIGURE 3 – Extraction depuis PDF

#### 4.4 Défis de cette phase :

Variabilité des formats PDF : Nécessité d'un prompt robuste

Valeurs composées : Gestion des formats "10/8" nécessitant un parsing spécifique

Abréviations médicales non standardisées

Présence de données manuscrites ou annotations

Tables multi-pages avec en-têtes répétés

Valeurs manquantes ou non détectées

## 5 Phase 2 : Analyse Exploratoire des Données (EDA)

### 5.1 Objectifs

Comprendre la distribution des variables

Identifier les patterns médicaux

Déetecter les anomalies et outliers

Analyser les corrélations

### 5.2 Statistiques Descriptives

#### Distribution de la Variable Cible

- Proportion Low / Optimal / High responders
- Vérification de l'équilibre des classes

#### Statistiques Univariées

- Mesures de tendance centrale (moyenne, médiane, mode)
- Dispersion (écart-type, IQR, min/max)
- Distribution (histogrammes, box plots)

Statistiques descriptives :				
	cycle_number	Age	n_Follicles	AFC
count	501.000000	495.000000	468.000000	262.000000
mean	1.441118	31.735354	16.551282	12.286260
std	0.659565	4.676656	10.541421	6.679164
min	1.000000	24.000000	1.000000	3.000000
25%	1.000000	28.000000	8.000000	7.000000
50%	1.000000	32.000000	15.000000	12.000000
75%	2.000000	35.000000	24.000000	16.000000
max	3.000000	45.000000	46.000000	29.000000

FIGURE 4 – Enter Caption

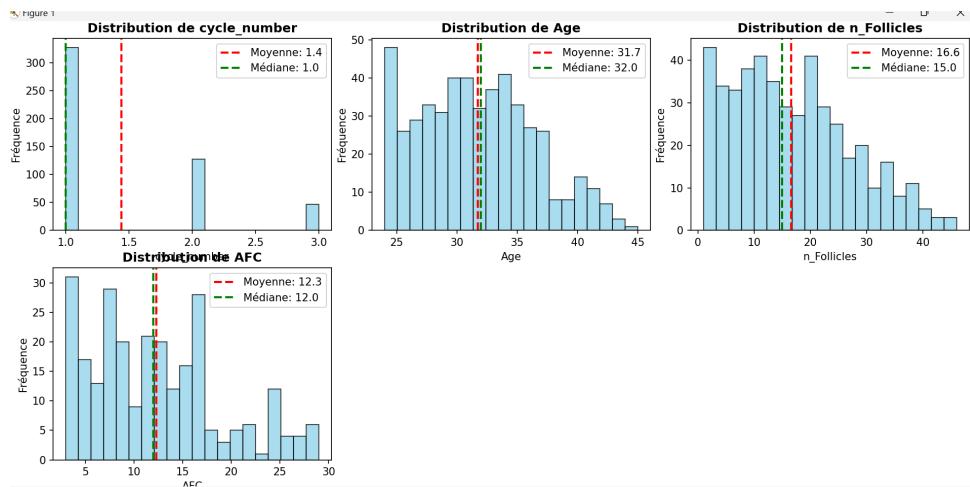


FIGURE 5 – Enter Caption

### 5.3 Analyse des Corrélations

#### Matrice de Corrélation

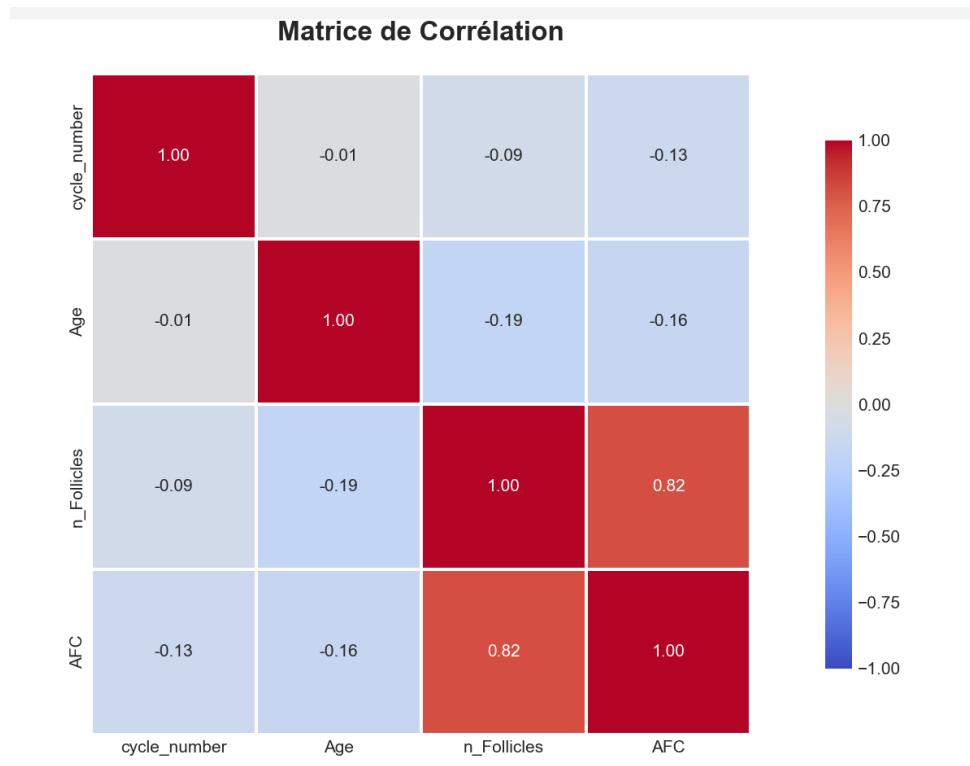


FIGURE 6 – Matrice de corrélation

- AMH ↔ AFC : forte corrélation positive
- Age ↔ AMH : corrélation négative (déclin avec l'âge)
- N\_Follicles ↔ E2\_day5 : corrélation positive
- AMH/AFC ↔ Patient\_Response : corrélations significatives

## 5.4 Insights Cliniques et Patterns

### Effet de l'Âge

- Déclin de la réserve ovarienne après 35 ans
- Interaction âge-AMH : poids prédictif variable selon l'âge

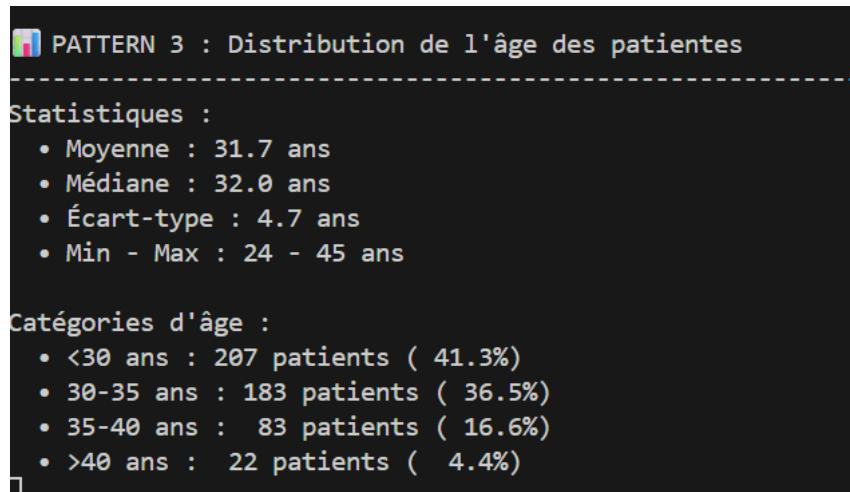


FIGURE 7 – DistributionAge

### Impact des Protocoles

- Efficacité différentielle selon le profil de réserve
- Fixed antagonist : adapté aux réponses normales
- Flexible antagonist : meilleur contrôle des high responders

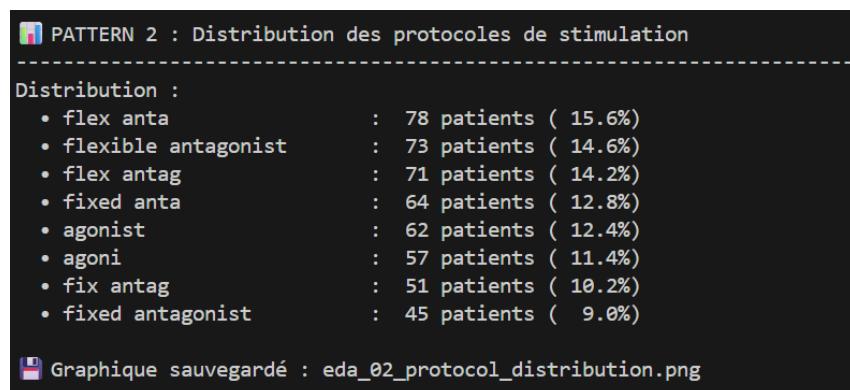


FIGURE 8 – Enter Caption

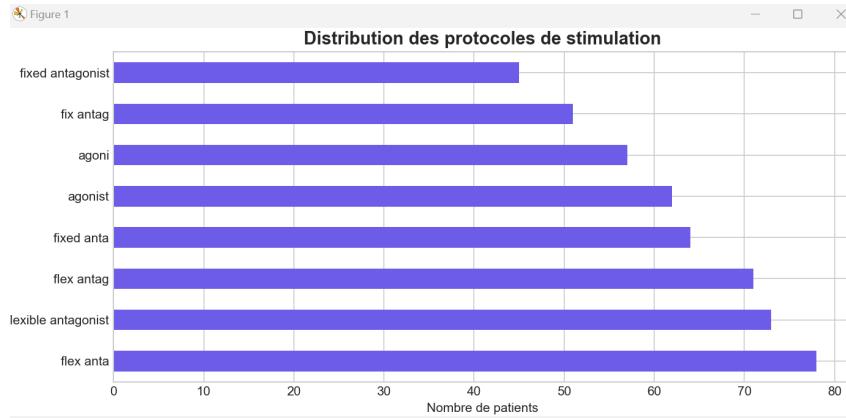


FIGURE 9 – Enter Caption

#### 5.4.1 Visualisation des Distributions

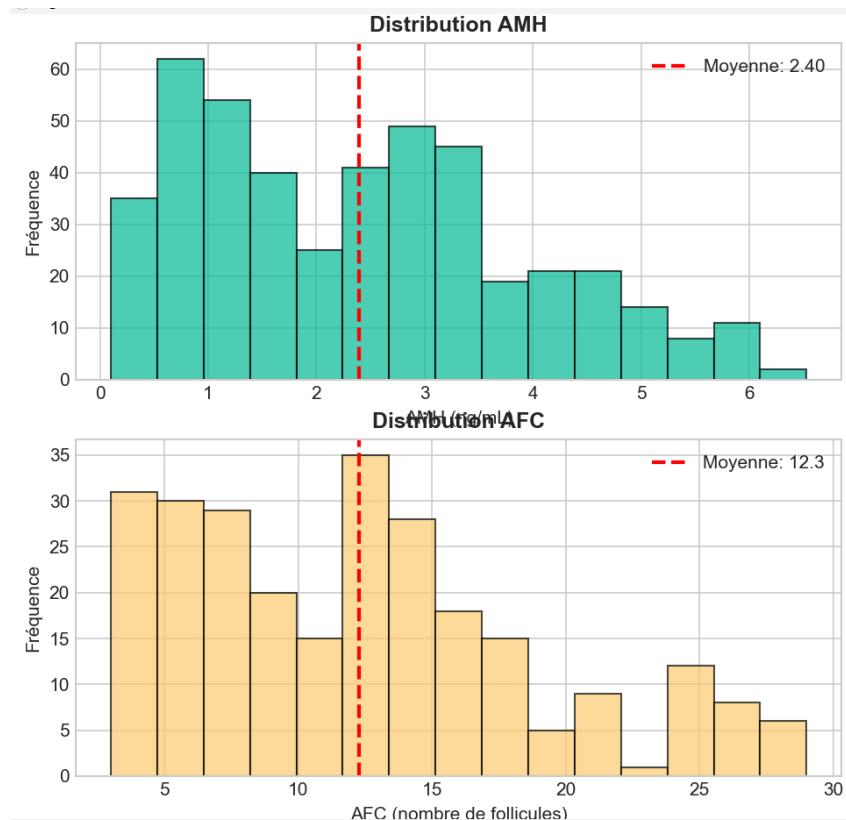


FIGURE 10 – Enter Caption

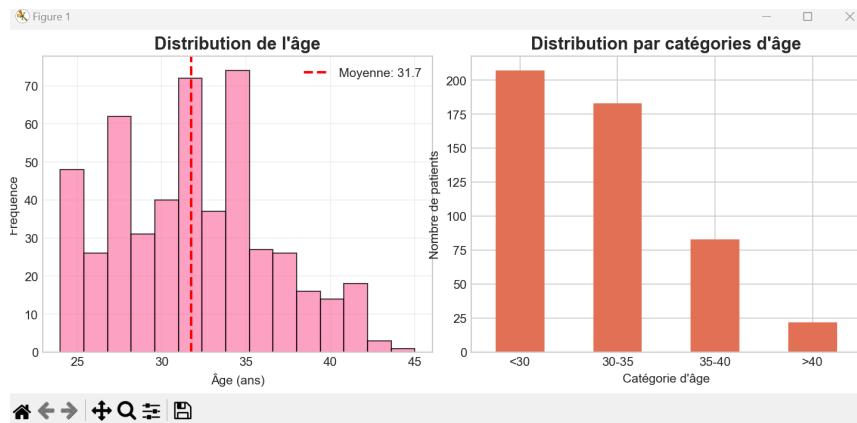


FIGURE 11 – Enter Caption

## Résumé de cette phase



FIGURE 12 – Enter Caption

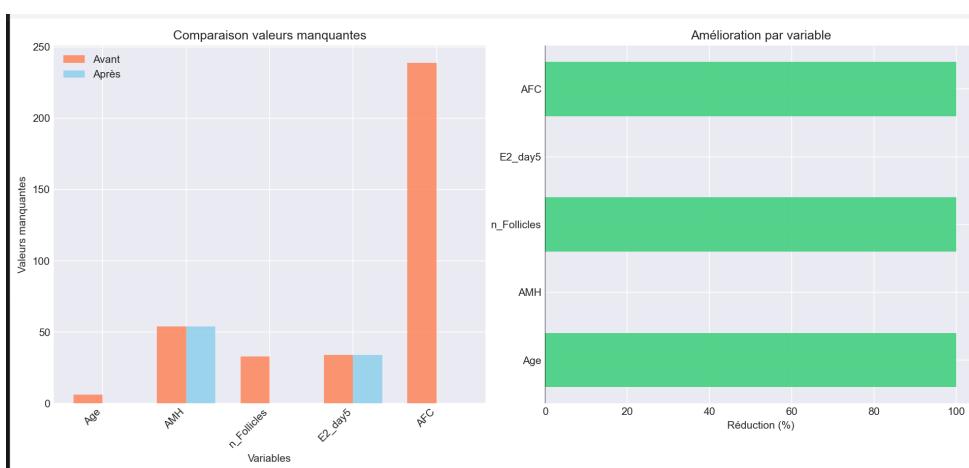


FIGURE 13 – Aucune valeurs manquante

```
RÉSUMÉ DES INSIGHTS
=====
● Principaux insights :
1. Le protocole le plus utilisé est 'flex anta' (15.6%)
2. Population relativement jeune (âge moyen : 31.7 ans)
3. Corrélation forte entre AMH_numeric et AFC (r=0.77)

=====
✓ ANALYSE TERMINÉE
=====
```

FIGURE 14 – Enter Caption

```
=====
✓NETTOYAGE MÉDICAL TERMINÉ - AFC PRÉSERVÉE
=====

→ Justification : r=0.77 avec AMH, variable cruciale ...

✓ Age imputé : médiane = 32.0
✓ AMH_numeric extrait
✓ E2_day5_numeric extrait
✓ AMH_numeric imputé : médiane = 2.30
✓ n_Follicles imputé : médiane = 15.00
✓ E2_day5_numeric imputé : médiane = 782.25
✓ AFC imputé intelligemment : 239 valeurs (r=0.77 avec AMH)
✓ Normalisation RobustScaler appliquée
✓ Protocol encodé

✓ Nettoyage terminé
• Patients : 501
• Colonnes : 17
=====
```

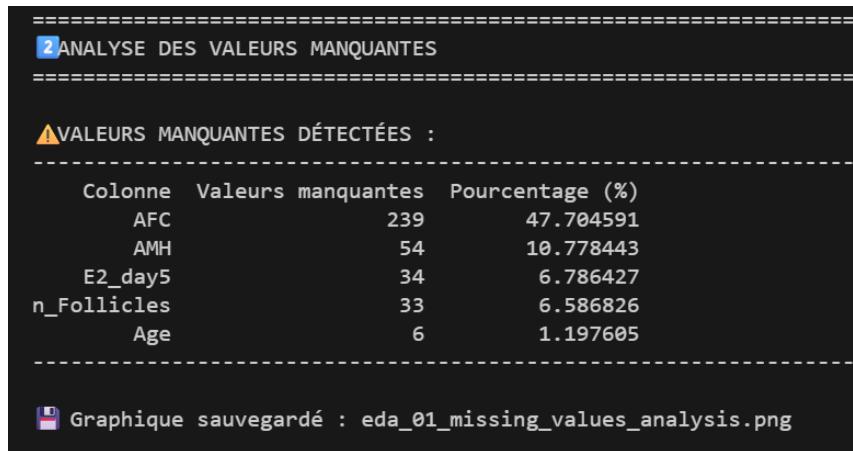
FIGURE 15 – Enter Caption

## 6 Phase3 : Prétraitement et Nettoyage

---

### 6.0.1 Détection et Gestion des Valeurs Manquantes

- Analyse du taux de valeurs manquantes par variable



- Stratégies selon le type de variable :
- Variables numériques : imputation par médiane (robuste aux outliers)

```
=====
ÉTAPE 2 : IMPUTATION DE AGE (MÉDIANE UNIQUEMENT)
=====

👉 Imputation de Age :
-----
• Valeurs manquantes : 6 (1.2%)
• Médiane de Age : 32.00 ans
• Méthode : MÉDIANE (règle médicale stricte)
✓ 6 valeurs imputées avec la médiane
-----
```

FIGURE 16 – Imputations de l'âge avec mediane

- Variables catégorielles : mode ou création d'une catégorie «Unknown»
- Imputation Avancée (IterativeImputer) : Exploite la forte corrélation AFC-AMH ( $r=0.77$ ) pour une imputation plus précise et médicalement cohérente.

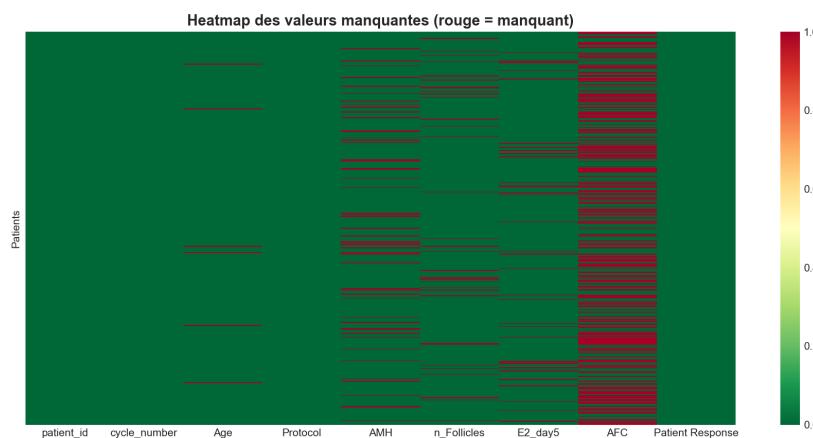


FIGURE 17 – Visualisation des valeurs manquantes

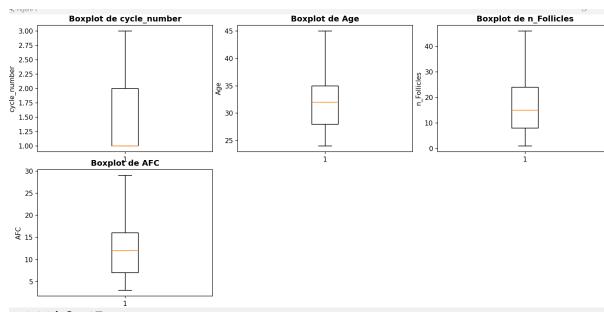


FIGURE 19 – Détection valeurs aberrantes

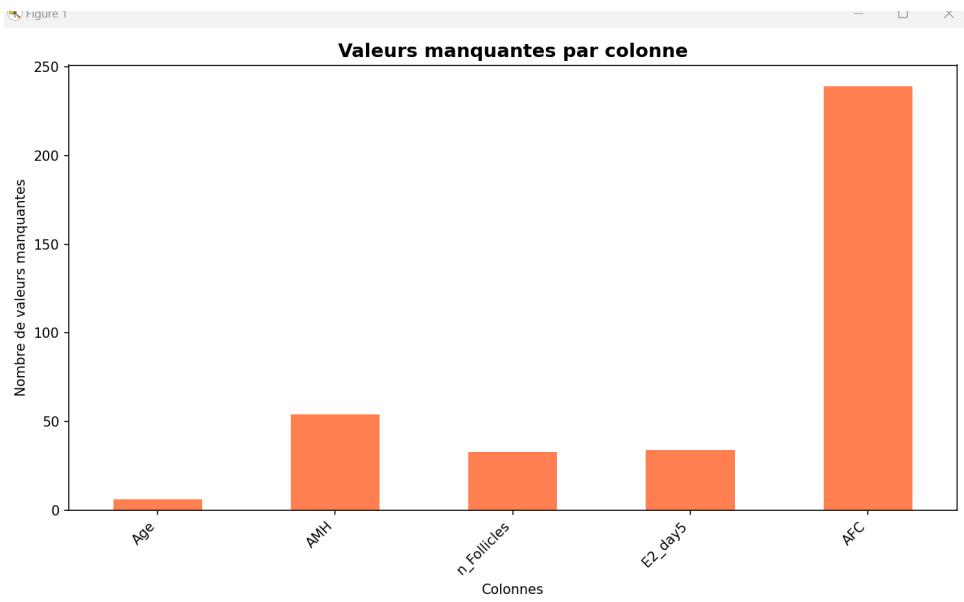


FIGURE 18 – Valeurs manquantes par colonnes

### 6.0.2 Détection des Valeurs Aberrantes

- Méthode IQR (Interquartile Range) : valeurs hors  $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$
- Z-score : valeurs avec  $|z| > 3$
- Validation clinique : vérification que les plages correspondent aux normes biologiques
- Décision : correction, suppression ou conservation selon le contexte clinique

### 6.0.3 Détection des Doublons

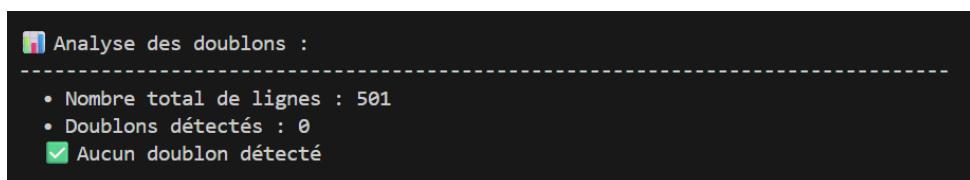


FIGURE 20 – Détection des Doublons

#### 6.0.4 Normalisation des Variables Numériques

- StandardScaler :  $(x - \mu)/\sigma \rightarrow$  distribution centrée réduite
- Ou MinMaxScaler :  $x \in [0, 1]$  si distribution non gaussienne
- RobustScaler : résistant aux outliers (médiane et IQR)
- Normalisation par variable pour éviter domination par échelle

```
ÉTAPE 4 : NORMALISATION AVEC ROBUSTSCALER
=====
RULE MEDICALE STRICTE :
-----
✖ MinMaxScaler : INTERDIT (détruit info biologique)
✖ StandardScaler : INTERDIT (sensible aux outliers)
✓ RobustScaler : SEUL AUTORISÉ (basé sur médiane/IQR)

Variables à normaliser : Age, AMH_numeric, n_Follicles, E2_day5_numeric
Age :
-----
Avant : min=24.00, max=45.00, median=32.00
Médiane : 32.00
IQR : 7.00
Après : median=0.00, IQR=1.00

AMH_numeric :
-----
Avant : min=0.10, max=6.53, median=2.30
Médiane : 2.30
IQR : 2.02
Après : median=0.00, IQR=1.00
```

-> Choix du RobustScaler :

- Utilise la médiane et l'IQR (Interquartile Range)
- Robuste aux outliers (important pour les biomarqueurs)
- Préserve les valeurs extrêmes médicalement significatives (high responders)

#### 6.0.5 Encodage des Variables Catégorielles

- Protocol : Encodage ordinal

```
Protocoles uniques trouvés : ['flexible antagonist' 'fix antag' 'flex anta' 'fixed anta' 'agonist'
'flex antag' 'agoni' 'fixed antagonist']
Agonist : ['agonist']
Flexible Antagonist : ['flexible antagonist', 'flex anta', 'flex antag']
Fixed Antagonist : ['fix antag', 'fixed anta', 'fixed antagonist']
✓ Protocol encodé : valeurs uniques après encodage -> [ 1.  2.  0. -1.]
```

FIGURE 21 – Encodage du Protocol

- Patient\_Response (cible) : Label Encoding (0 :low, 1 :optimal, 2 :high)

## 7 Phase 4 : Entraînement des ML

---

### 7.1 Objectif

L'objectif de cette phase est de **prédir la réponse des patientes au traitement IVF** selon trois catégories cliniques : *low*, *optimal* et *high*. Pour cela, plusieurs algorithmes de classification supervisée ont été entraînés, optimisés et comparés. L'objectif final est de :

- identifier le modèle le plus performant selon le **F1-score pondéré**, adapté aux classes déséquilibrées ;
- sauvegarder le meilleur modèle et ses hyperparamètres optimaux ;
- fournir une base fiable pour les phases d'interprétabilité, d'évaluation clinique et de déploiement.

### 7.2 Algorithmes Utilisés

Cinq modèles supervisés ont été testés afin de couvrir plusieurs familles d'algorithmes (linéaires, arbres, ensembles, marges maximales) :

#### Régression Logistique Multinomiale

- Modèle linéaire simple et fortement interprétable.
- Adapté à la classification multi-classes.
- Fournit directement des probabilités.

#### Random Forest

- Ensemble d'arbres de décision construit par bagging.
- Robuste aux données bruitées et aux outliers.
- Réduit la variance et améliore la stabilité des prédictions.

#### Gradient Boosting

- Approche de boosting séquentiel corrigant les erreurs des arbres précédents.
- Excellent comportement sur données tabulaires.
- Souvent le modèle le plus performant dans des contextes cliniques structurés.

#### AdaBoost

- Boosting adaptatif basé sur des “faibles apprenants”.
- Donne plus de poids aux erreurs pour affiner la frontière de décision.
- Particulièrement efficace lorsque les données sont bien séparables.

### Support Vector Classifier (SVC)

- Apprentissage basé sur des hyperplans maximisant la marge entre classes.
- Kernel RBF utilisé pour capturer la non-linéarité.
- Probabilités calibrées via la méthode de Platt.

## 7.3 Étapes Principales de l'Entraînement

### 1. Chargement et Prétraitement du Dataset

- Les données nettoyées proviennent du module IVFDataset.
- Elles incluent les valeurs biologiques, hormonales, antécédents médicaux et variables cliniques.
- Les features et labels sont extraits sous forme de  $(X, y)$ .

### 2. Division des Données

- Split : 80% train, 10% validation, 10% test.
- Split stratifié pour conserver la distribution Low/Optimal/High.
- Fixation du random seed pour reproductibilité.

### 3. Préparation des Données

- Option de normalisation via StandardScaler.
- Pipeline automatique pour garantir l'absence de fuite d'information (data leakage).

### 4. Initialisation des Modèles et Grilles d'Hyperparamètres

Pour chaque modèle :

- définition d'une grille d'hyperparamètres,
- intégration dans un pipeline Scikit-learn,
- préparation pour une optimisation systématique via GridSearchCV.

### 5. Entraînement avec GridSearchCV

- Validation croisée stratifiée (StratifiedKFold).
- Score principal : **F1-score pondéré**.
- Recherche exhaustive des hyperparamètres optimaux.

### 6. Sélection et Sauvegarde du Meilleur Modèle par Algorithme

Pour chaque algorithme :

- sauvegarde du meilleur modèle (.pkl),
- sauvegarde des hyperparamètres optimaux (.json),
- archivage dans un dossier avec horodatage.

## 7. Historisation

- Création d'un historique complet : nom du modèle, hyperparamètres, score final, date.
- Stockage dans la variable `training_history`.

## 7.4 Résultat Attendu

À l'issue de cette phase :

- tous les modèles candidats sont entraînés et sauvegardés ;
- les hyperparamètres optimaux sont documentés ;
- une comparaison objective pourra être effectuée lors de la phase d'évaluation ;
- un modèle “gagnant” sera sélectionné pour déploiement selon son F1-score pondéré.

## 8 Phase 5 : Évaluation et Choix du Modèle

### 8.1 Stratégie d'Évaluation

L'objectif de cette phase est d'évaluer les différents modèles entraînés afin d'identifier celui offrant la meilleure capacité de prédiction de la réponse des patientes au traitement IVF (classes : *low*, *optimal*, *high*). L'évaluation repose principalement sur le **F1-score pondéré**, adapté aux jeux de données déséquilibrés.

#### Jeu de Test

L'ensemble de test est généré par le module `IVFDataset` selon la configuration définie lors de l'entraînement :

- Split : 80% entraînement, 10% validation, 10% test
- Stratification pour préserver la distribution des classes
- Données normalisées si demandé
- Variables utilisées : `X_test` (features), `y_test` (labels), `class_names` (noms des classes)

Le jeu de test n'est **jamais utilisé pendant l'entraînement**, garantissant une évaluation non biaisée.

### 8.2 Modèles Évalués

Les cinq modèles suivants, préalablement entraînés et sauvegardés au format `.pkl`, sont évalués :

Modèle	Description
Logistic Regression	Modèle linéaire multinomial, baseline interprétable.
Random Forest	Ensemble d'arbres de décision robuste, réduit la variance.
Gradient Boosting	Boosting séquentiel corrigéant les erreurs précédentes.
AdaBoost	Boosting adaptatif basé sur des estimateurs faibles.
SVC	Classifieur à hyperplans maximisant les marges, kernels linéaire/RBF.

Chaque modèle est évalué sans réentraînement, en utilisant les poids optimisés obtenus via `GridSearchCV`.

### 8.3 Métriques d'Évaluation

Pour chaque modèle, les métriques suivantes sont calculées :

- **Accuracy** : proportion de bonnes prédictions.
- **Precision pondérée** : moyenne pondérée selon l'importance des classes.

- **Recall pondéré** : taux de vrais positifs pondéré.
- **F1-score pondéré** : **métrique principale** pour le choix du meilleur modèle.

$$F1 = \frac{2 \times (\text{Precision} \times \text{Recall})}{\text{Precision} + \text{Recall}}$$

- **Matrice de confusion** : analyse des erreurs par classe.
- **Classification Report** : inclut précision, rappel, F1 et support.

```
=====
Evaluating gradient_boosting
=====

INFO:__main__:Accuracy: 0.8515
INFO:__main__:Precision: 0.8563
INFO:__main__:Recall: 0.8515
INFO:__main__:F1-score: 0.8524

Classification Report:
precision    recall   f1-score   support
low          0.79      0.87      0.83       31
optimal       0.84      0.84      0.84       45
high          0.95      0.84      0.89       25

accuracy                  0.85       101
macro avg       0.86      0.85      0.86       101
weighted avg    0.86      0.85      0.85       101

INFO:__main__:Sample 0: {'low': '0.4%', 'optimal': '99.1%', 'high': '0.5%'}
INFO:__main__:Sample 1: {'low': '2.6%', 'optimal': '80.4%', 'high': '17.0%'}
INFO:__main__:Sample 2: {'low': '97.2%', 'optimal': '0.9%', 'high': '1.9%'}
INFO:__main__:Sample 3: {'low': '4.4%', 'optimal': '6.2%', 'high': '89.4%'}
INFO:__main__:Sample 4: {'low': '4.5%', 'optimal': '90.0%', 'high': '5.4%'}
INFO:__main__:
```

FIGURE 22 – Evaluate GredientBoost

```
=====
Evaluating random_forest
=====

INFO:__main__:Accuracy: 0.8713
INFO:__main__:Precision: 0.8734
INFO:__main__:Recall: 0.8713
INFO:__main__:F1-score: 0.8715

Classification Report:
precision    recall   f1-score   support
low          0.82      0.90      0.86       31
optimal       0.88      0.84      0.86       45
high          0.92      0.88      0.90       25

accuracy                  0.87       101
macro avg       0.87      0.88      0.87       101
weighted avg    0.87      0.87      0.87       101
```

FIGURE 23 – RandomForest

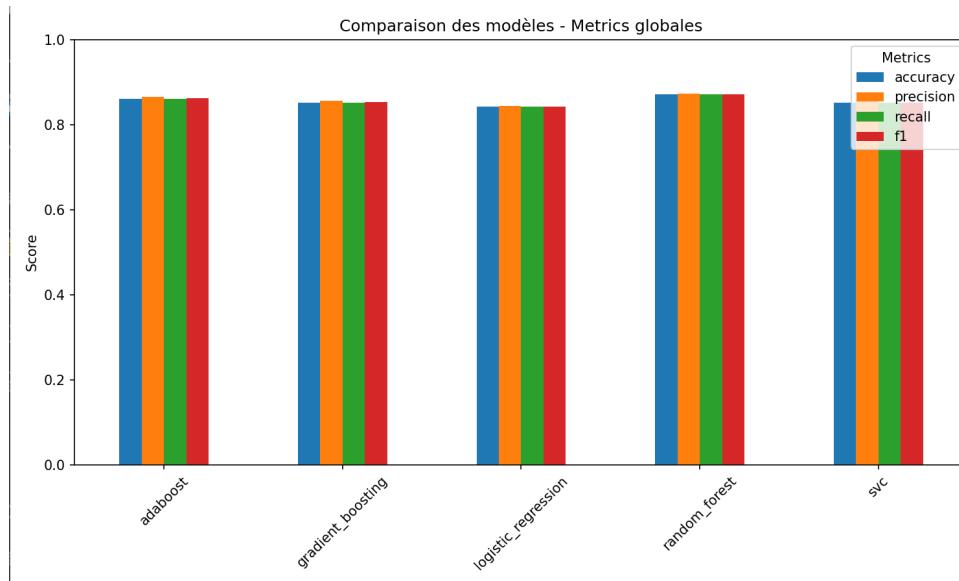


FIGURE 25 – Comparaison entre les modèles

## 8.4 Analyse et Visualisations

- **Bar Charts Comparatifs** : comparaison directe des modèles sur Accuracy, Precision weighted, Recall weighted et F1-score weighted.

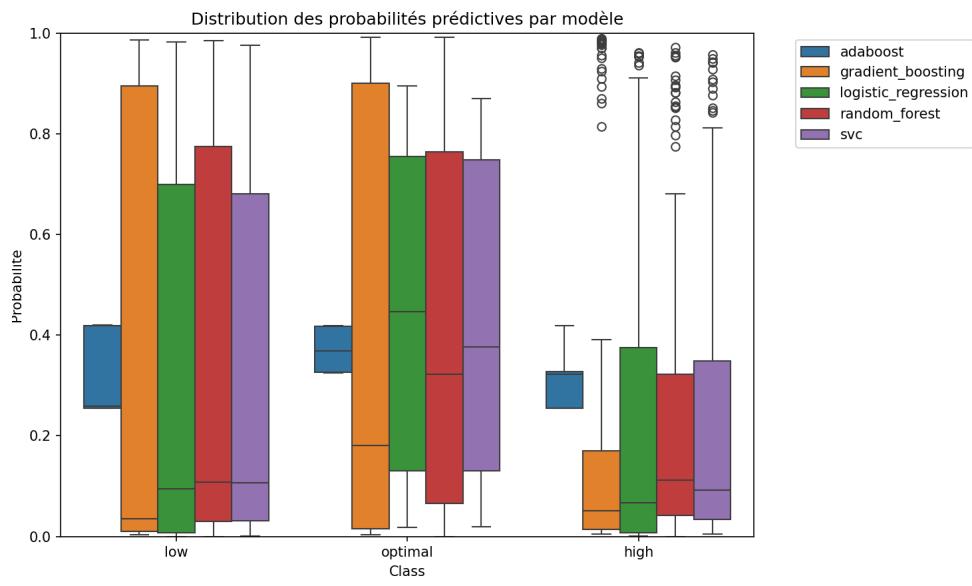


FIGURE 24 – Comparaison entre les models

- **Heatmaps de Matrices de Confusion** : permet d'observer les classes bien prédites et les confusions.

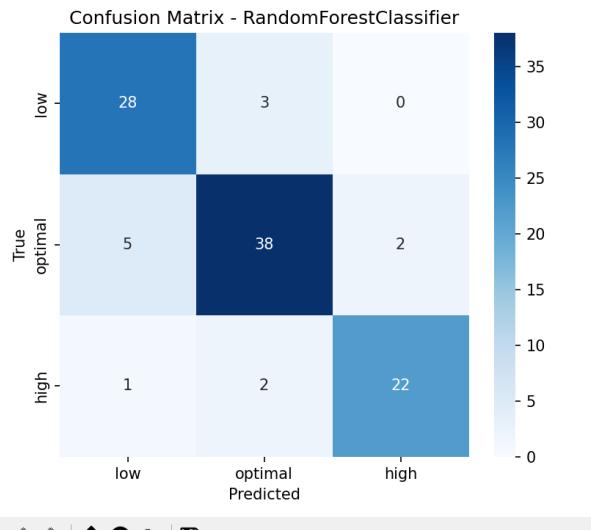


FIGURE 26 – Matrice de confusion de RandomForest

- **Analyse des Probabilités** : boxplots et quelques prédictions avec probabilités pour vérifier la calibration et la confiance des modèles.

## 8.5 Sélection du Meilleur Modèle

### Critère de Sélection

Le meilleur modèle est défini comme celui ayant le **F1-score pondéré le plus élevé sur le jeu de test**, justifié par :

- la présence éventuelle de déséquilibre des classes,
- le compromis entre précision et rappel,
- la robustesse du F1-score pour les problèmes multiconcaves.

```
Meilleur modèle sélectionné : random_forest avec F1-score pondéré = 0.8715
INFO: __main__:Description du meilleur modèle (random_forest): RandomForestClassifier(max_depth=20, min_samples_split=5, n_jobs=-1,
                                                 random_state=42)
INFO: __main__:Le meilleur modèle a été sauvegardé dans : saved_models\best_model.pkl
```

FIGURE 27 – Choix du meilleurModel

## 9 Phase 6 : Prédiction

---

### 9.1 Objectif

Cette phase consiste à prédire la réponse des patientes au traitement IVF en utilisant le modèle sélectionné lors de la phase d'évaluation. La réponse est stratifiée en trois classes : *low*, *optimal* et *high*. L'objectif est de fournir pour chaque patiente :

- La classe prédite (*predicted response*)
- La confiance de la prédiction (*confidence*)
- La distribution des probabilités pour chaque classe
- Une interprétation clinique basée sur les valeurs de probabilité
- Des recommandations cliniques personnalisées

### 9.2 Chargement du Modèle

Le modèle utilisé pour la prédiction est le meilleur modèle sauvegardé (`best_model.pkl`) accompagné des préprocesseurs :

- **Scalage des variables** : `scaler.pkl`
- **Encodage des classes** : `label_encoder.pkl`
- **Informations sur les features** : `feature_info.pkl`
- **Métadonnées du modèle** : `best_model_metadata.json` (optionnel)

### 9.3 Prétraitement des Données

Avant la prédiction, les données patient sont prétraitées :

- Conversion en `DataFrame` si nécessaire
- Vérification et création des features attendues par le modèle
- Application du `scaler` sur les variables numériques (*Age*, *AMH*, *N\_Follicles*, *E2\_day5*, *AFC*)
- Encodage des variables catégorielles, notamment *Protocol*
- Remplissage automatique des features manquantes avec des valeurs par défaut

### 9.4 Prédiction

Le modèle prédit pour chaque patiente :

- La classe prédite : `predicted_response`
- L'indice de classe : `predicted_class_index`
- Les probabilités par classe : `probabilities`
- La confiance maximale : `confidence`

Des fonctions spécifiques permettent :

- **predict\_single\_patient** : prédiction détaillée pour un patient avec interprétation clinique et recommandations
- **predict\_batch** : prédiction pour plusieurs patientes et sauvegarde des résultats dans un fichier CSV

## 9.5 Interprétation Clinique et Recommandations

Pour chaque patiente, le modèle fournit une interprétation et des recommandations personnalisées :

- **Interprétation clinique** : résumé de la probabilité et de la confiance, avec classification en haute, moyenne ou faible confiance.
- **Recommandations** :
  - *Low responders* : augmenter la dose initiale, suivi plus fréquent, évaluer la réserve ovarienne, considérer protocoles alternatifs.
  - *High responders* : réduire la dose pour limiter les risques d'OHSS, planifier un déclencheur agoniste, suivi étroit, envisager stratégie de *freeze-all*.
  - *Optimal responders* : protocole standard, suivi régulier, bonne probabilité de succès.

## 9.6 Exemple de Prédiction

- Patient : 29 ans, cycle numéro 1, protocole *flex anta*, AMH 5.62, 15 follicules, E2\_day5 699.82, AFC 17
- Résultat :
  - Classe prédite : *high*
  - Confiance : 92%
  - Probabilités : low 5%, optimal 3%, high 92%
  - Interprétation : *Haute probabilité d'une réponse élevée au traitement, suivi recommandé pour OHSS.*
  - Recommandations : dose initiale plus faible, déclencheur agoniste, surveillance étroite des niveaux d'estradiol.

## 9.7 Résumé

La phase de prédiction permet de transformer un modèle machine learning optimisé en un outil décisionnel clinique, offrant à la fois :

- Des prédictions quantitatives (classe et probabilités)
- Des interprétations cliniques compréhensibles
- Des recommandations personnalisées pour la prise en charge de chaque patiente

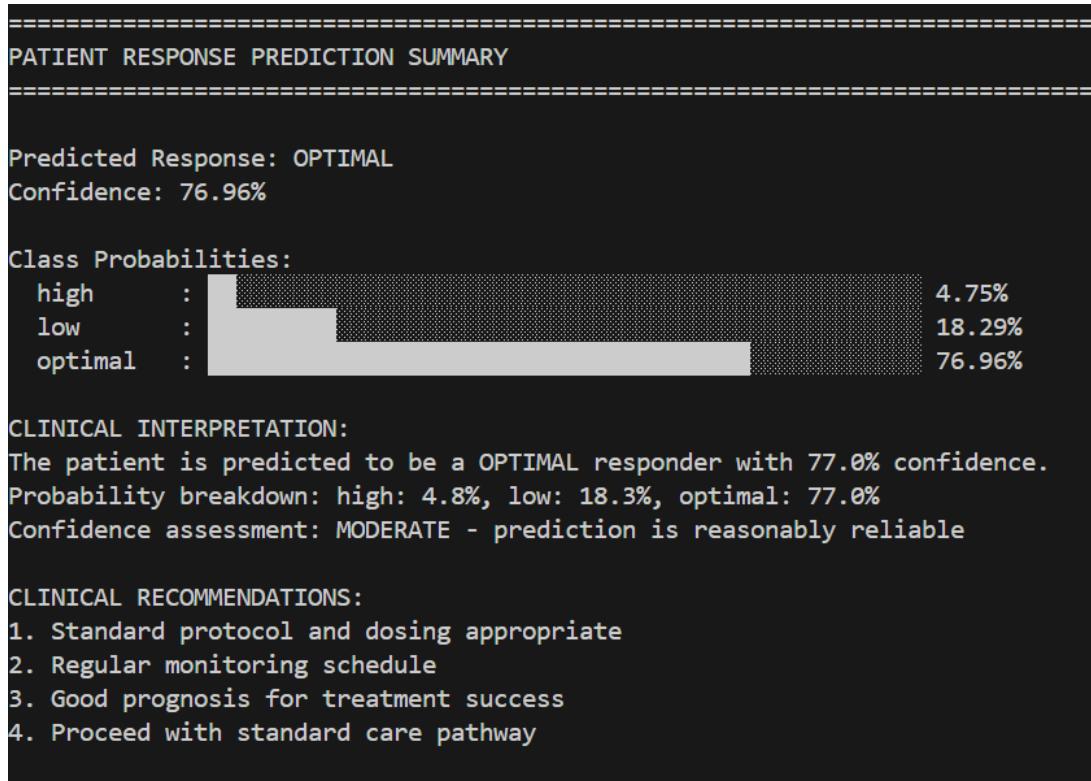


FIGURE 28 – Enter Caption

## 10 Phase 7 : Interface Utilisateur et Intégration du Modèle

### 10.1 Description

Cette partie présente l'interface développée pour l'interaction avec le modèle de prédition. Elle combine un **backend Flask** pour la gestion des API et des requêtes et un **frontend Streamlit** pour l'affichage interactif des résultats.

#### — Backend Flask :

- Sert de serveur API pour recevoir les données patient
- Gère la communication avec le modèle de prédition
- Retourne les résultats au frontend en format JSON

#### — Frontend Streamlit :

- Interface utilisateur simple et interactive
- Formulaires pour saisir les caractéristiques des patientes
- Visualisation des résultats : classe prédite, probabilités, interprétation clinique et recommandations

#### — Intégration du modèle :

- Le modèle de prédition est chargé via le backend Flask
- Streamlit envoie les données utilisateur à Flask
- Les résultats retournés sont affichés en temps réel sur le frontend

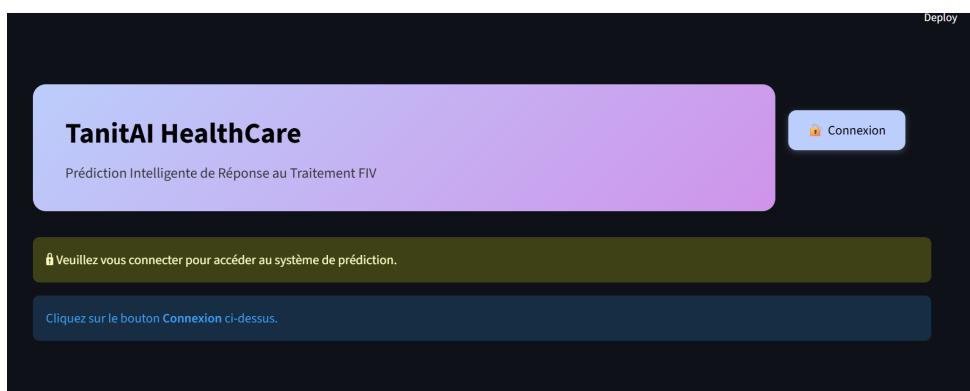


FIGURE 29 – Home Page

**Analyse Patiente Individuelle**

Âge: 32 AMH (ng/mL): 2.50

Numéro de Cycle: 1 AFC: 15

Protocole de Stimulation: agonist Nombre de Follicules: 15

E2 Jour 5 (pg/mL): 300.00

Lancer la Prédiction

FIGURE 31 – Formulaire du client

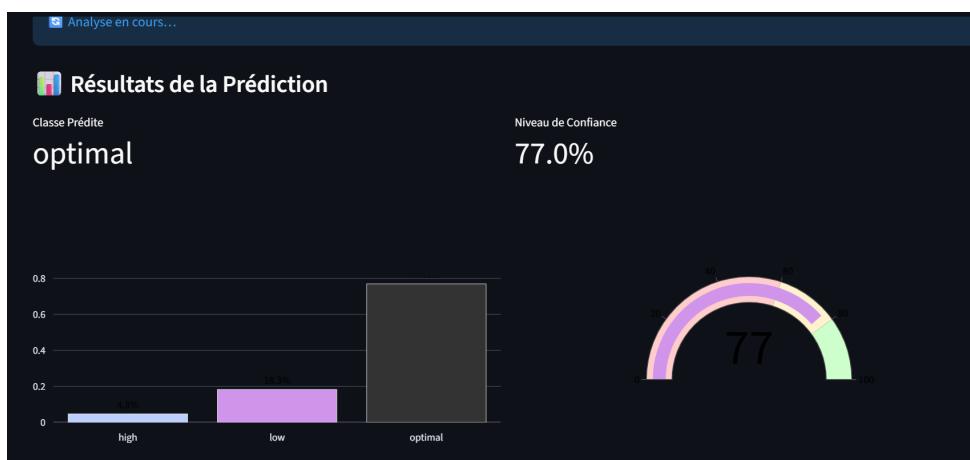


FIGURE 32 – Résultat de prediction

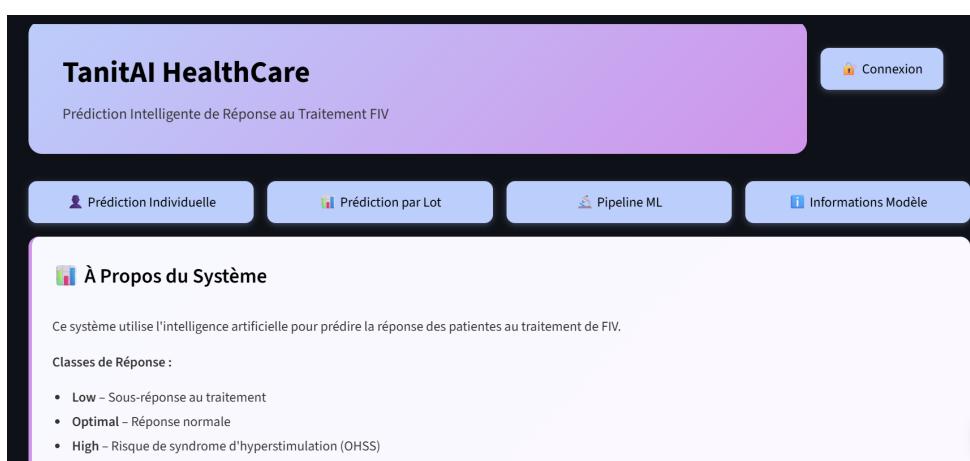


FIGURE 30 – Page de prediction

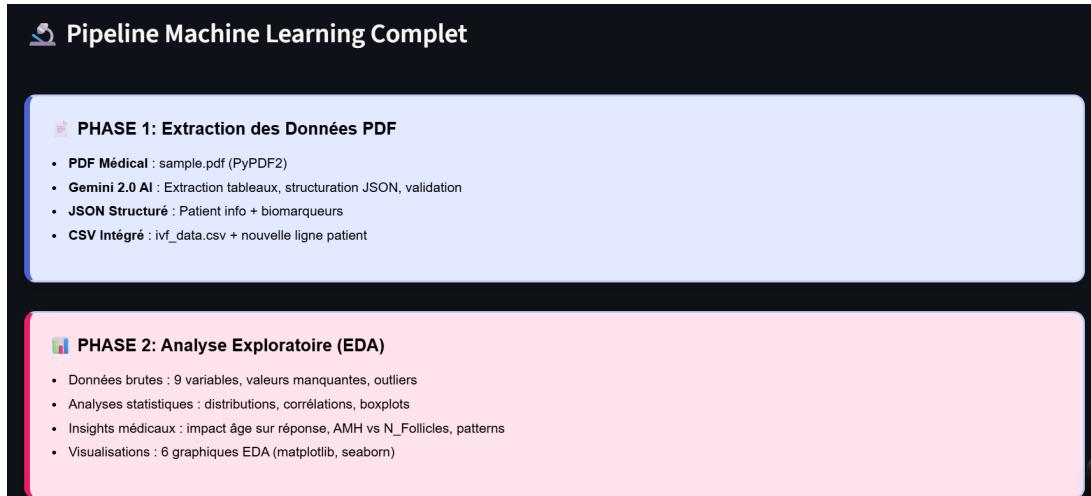


FIGURE 33 – Pipeline

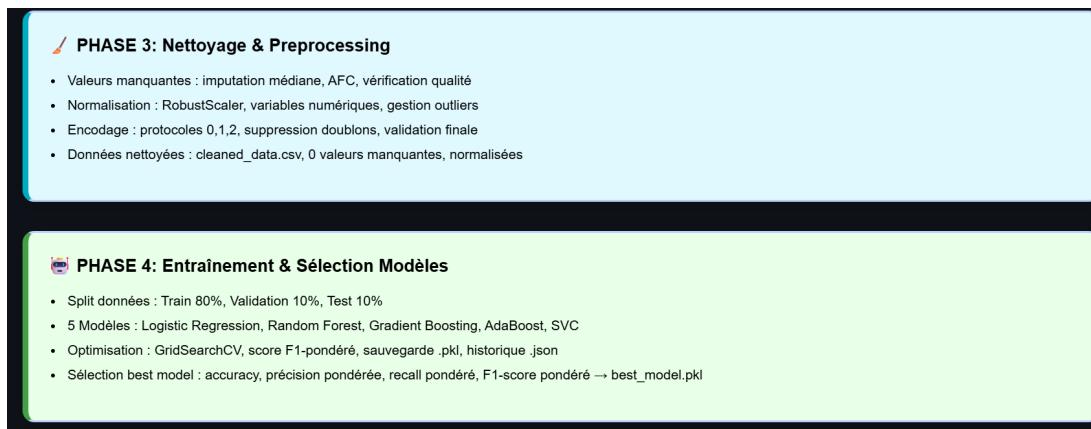


FIGURE 34 – Enter Caption



## Informations sur le Modèle

```
{  "categorical_features": [],  "classes": [    0: "high",    1: "low",    2: "optimal"  ],  "features": [    0: "cycle_number",    1: "Age_robust",    2: "n_Follicles_robust",    3: "E2_day5_numeric_robust",    4: "AFC_robust"  ],  "model_type": "RandomForestClassifier",  "n_features": 5}
```

FIGURE 35 – Information sur Modele

## 11 Perspectives Importantes

---

### 11.1 Recommandation avec LLM

Dans les prochaines évolutions du projet, la phase de **recommandation finale** pourrait être réalisée à l'aide d'un **Large Language Model (LLM)**. L'idée serait que le LLM prenne en entrée :

- L'historique médical des patientes
- Les prédictions générées par le modèle de machine learning
- Les données médicales contextuelles et cliniques

et fournit des recommandations personnalisées plus fiables.

Cette approche présente un gain potentiel en **précision et contextualisation clinique**, mais elle nécessite des ressources computationnelles importantes et du temps d'exécution, ce qui n'a pas permis de finaliser cette phase dans le temps imparti.

### 11.2 Visualisation du pipeline

Pour améliorer la compréhension et la traçabilité du processus, il serait intéressant d'intégrer une **visualisation complète du pipeline**, incluant :

- Le téléchargement et la préparation des données (PDF, CSV, etc.)
- L'extraction et le prétraitement des données
- L'analyse via les modèles de machine learning
- La génération des prédictions et des recommandations
- La production des conclusions et rapports

### 11.3 Documentation et mots-clés

Une documentation complète serait également essentielle pour :

- Décrire chaque étape du pipeline
- Fournir des mots-clés et définitions dans le domaine médical et informatique
- Faciliter la maintenance et l'évolution du projet

### 11.4 Version et contraintes

Ce travail peut être considéré comme une **version 0** du projet, réalisée en **moins de 48 heures** en raison des contraintes de devoirs et de validation. Les perspectives présentées ici serviront de base pour les améliorations futures et l'intégration des fonctionnalités avancées.